

# Contenidos

|                                                                            |          |
|----------------------------------------------------------------------------|----------|
| <b>OBJETIVOS</b>                                                           | <b>2</b> |
| <b>MARCO TEÓRICO</b>                                                       | <b>3</b> |
| <b>PRERREQUISITOS</b>                                                      | <b>4</b> |
| <b>DESARROLLO</b>                                                          | <b>5</b> |
| Descripción del dataset . . . . .                                          | 5        |
| Variables utilizadas . . . . .                                             | 5        |
| Enlace de Github . . . . .                                                 | 5        |
| Estadísticas del repositorio . . . . .                                     | 5        |
| Avances del proyecto . . . . .                                             | 6        |
| Etapas de desarrollo . . . . .                                             | 7        |
| Etapa 1: Preparación de datos (Completada) . . . . .                       | 7        |
| Etapa 2: Aplicación de Splines Cúbicos (Parcialmente completada) . . . . . | 7        |
| Etapa 3: Aplicación de Mínimos Cuadrados (Pendiente) . . . . .             | 7        |
| Etapa 4: Validación del modelo (Pendiente) . . . . .                       | 7        |
| Etapa 5: Interpretación de los resultados (Pendiente) . . . . .            | 7        |
| Principales retos presentados . . . . .                                    | 8        |
| <b>REFERENCIAS</b>                                                         | <b>9</b> |

# OBJETIVOS

- Analizar la variación histórica de la calidad del aire en Estados Unidos y describir su posible relación con indicadores de salud pública.
- Estudiar el comportamiento histórico del AQI en las distintas regiones de Estados Unidos para identificar tendencias y variaciones mediante el análisis de los datos disponibles.
- Aplicar el método interpolación de datos de Splines Cúbicos para modelar el comportamiento de los datos históricos.

# MARCO TEÓRICO

Este proyecto busca analizar el Índice de Calidad del Aire (AQI) que es una herramienta desarrollada por la Agencia de Protección Ambiental de los Estados Unidos (EPA) con el objetivo de comunicar de manera sencilla el nivel de contaminación del aire y su posible impacto en la salud de la población. El AQI se divide en seis categorías principales, cada una asociada a un nivel de riesgo para la salud: buena (0–50), moderada (51–100), no saludable para grupos sensibles (101–150), no saludable (151–200), muy no saludable (201–300) y peligrosa (301 o más) [1].

El cálculo del AQI se basa en la medición de diferentes contaminantes atmosféricos regulados por la EPA, los que incluyen el ozono, monóxido de carbono, dióxido de nitrógeno, dióxido de azufre y material particulado. Cada uno de estos contaminantes tiene efectos sobre la salud humana, siendo que la exposición prolongada a estos contaminantes puede generar enfermedades respiratorias, agravar el asma, disminuir la función pulmonar e incrementar el riesgo de enfermedades cardiovasculares [1]. Por esta razón, resulta fundamental el monitoreo de la calidad del aire para la salud de la población.

En el contexto del análisis de datos históricos del periodo 1980–2021, se emplean los splines cúbicos naturales como método de interpolación por tramos. Este método permite aproximar el comportamiento del AQI mediante polinomios de tercer grado entre nodos consecutivos, garantizando suavidad en la representación. En particular, el spline cúbico natural impone condiciones de frontera libres, asumiendo que la segunda derivada en los extremos del intervalo es igual a cero, lo que permite modelar de forma continua la evolución del AQI a lo largo del tiempo [2]. Su aplicación será para la interpolación de los datos disponibles para analizar la variación del AQI dentro del intervalo observado.

Por otro lado, el método de mínimos cuadrados es una técnica de ajuste de curvas que permite encontrar una función que represente un conjunto de datos minimizando la suma de los errores cuadráticos. A diferencia de la interpolación, este método no busca pasar exactamente por todos los puntos, sino capturar la tendencia general del fenómeno [2]. En este proyecto, se utilizará para realizar extrapolaciones aproximadas del comportamiento del AQI, basadas en la tendencia obtenida.

# PRERREQUISITOS

- Dataset 1980-2021 Yearly Air Quality Index from the EPA. Se trabajara con este dataset que contiene registros del nivel de la calidad del aire en distintos estados y condados de Estados Unidos entre 1980 a 2021. Los datos fueron obtenidos a través de Kaggle [\[3\]](#).
- Biblioteca Numpy
- Biblioteca Pandas
- Biblioteca matplotlib

# DESARROLLO

## DESCRIPCIÓN DEL DATASET

El dataset usado contiene los registros anuales en relación a la calidad del aire en Estados Unidos durante el periodo entre 1980 y 2021.

El dataset incluye las siguientes variables: - State y County: Indican la ubicación geográfica de los registros. - Latitude y Longitude: Indican las coordenadas geográficas del condado. - Year: Representa el año en los que se realizaron los registros. - Median AQI: Representa un valor mediano del AQI que se registró durante el año. Será una de las variables principales para analizar la tendencia de la calidad del aire. - 90th Percentile AQI: Indica el valor máximo del AQI alcanzado en el 90 % de los días del año, excluyendo el 10 % que representaría los días más contaminados. - Max AQI: Indica el valor máximo del AQI registrado en el año. - Days with AQI: Indica la cantidad de días con registros de calidad del aire disponibles. - Good Days, Moderate Days, Unhealthy for Sensitive Groups Days, Unhealthy Days, Very Unhealthy Days y Hazardous Days: Representan la cantidad de días en el año en que la calidad del aire se encontró dentro de cada rango del índice AQI, clasificando según el nivel de riesgo para la salud. - Days CO, Days NO2, Days Ozone, Days SO2, Days PM2.5 y Days PM10: Representan la cantidad de días en que cada contaminante fue el principal responsable del nivel de AQI en ese día.

Durante la primera etapa de preprocesamiento se limpiaron los datos de la base y se agruparon los registros por regiones geográficas para facilitar el análisis comparativo.

## VARIABLES UTILIZADAS

Las siguientes variables fueron consideradas para su uso y se encuentran en el archivo que contiene el dataset normalizado:

| Variables      | Descripción                                                                                              |
|----------------|----------------------------------------------------------------------------------------------------------|
| Year           | Año del registro                                                                                         |
| Region         | Region geográfica asignada por el Censo                                                                  |
| Median AQI     | Mediana del AQI                                                                                          |
| AQI level days | Número de días clasificados según el nivel de la calidad del aire (Good, Moderate, Unhealthy, Hazardous) |
| Pollutant days | Número de días de según el contaminante principal (CO, NO2, O3, SO2, PM2.5, PM10)                        |

## ENLACE DE GITHUB

[https://github.com/DRKca089/Grupo2\\_SaludPublica.git](https://github.com/DRKca089/Grupo2_SaludPublica.git)

## ESTADÍSTICAS DEL REPOSITORIO

El desarrollo del proyecto se realizó en un repositorio compartido de GitHub, en el cual todos los integrantes participaron como colaboradores.

A continuación, se observan las estadísticas del repositorio y colaboradores:

- JUSTAILS: Justin Guevara
- DRKca089: Derek Cahuate
- lorent777: Elizabeth López

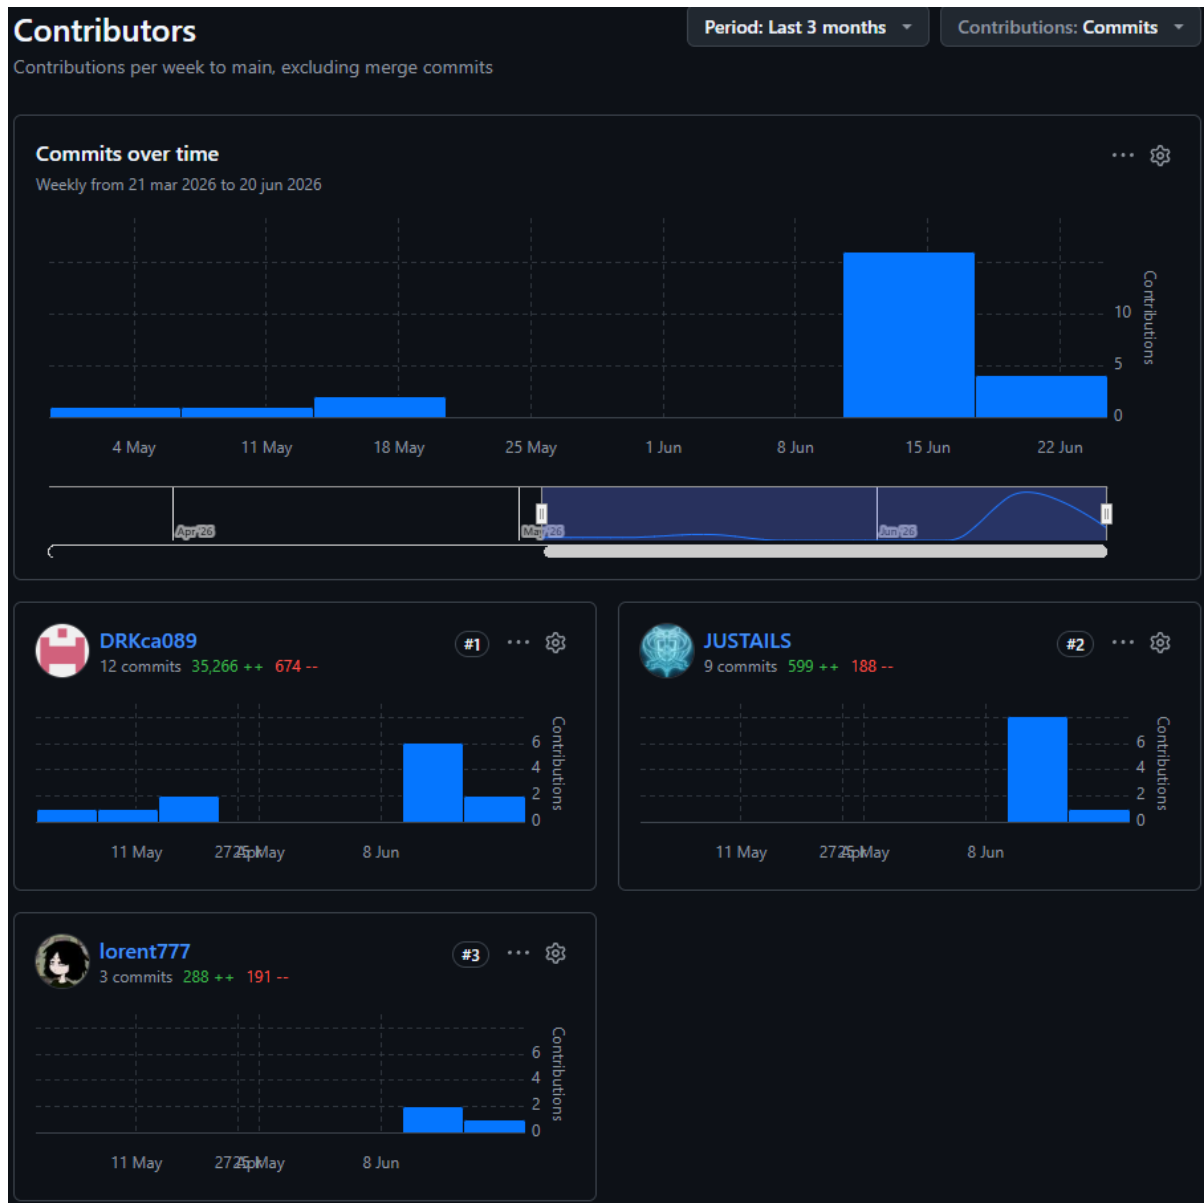


Figure 1: Gráfica de commits realizados al repositorio

## AVANCES DEL PROYECTO

Para la realización de la etapa 1, se implementó una función llamada `asignar_region`, para clasificar a los estados de Estados Unidos según las regiones definidas por el Censo (Northeast, Midwest, South y West) mediante la función. Asimismo, se desarrolló la función `limpiar_agrupar`, encargada de cargar el dataset original, eliminar los registros con valores nulos en las variables seleccionadas y excluir aquellos que no pertenecen a una región válida. En este proceso también se realiza el cálculo de proporciones para los distintos tipos de días según la calidad del aire y para los principales contaminantes. Finalmente, los datos son agrupados por región y año.

Como resultado, se obtuvo un dataset limpio que sera utilizado en las siguientes etapas.

En la etapa 2, se implementó el método `splineNatural`, el cual permite realizar interpolación mediante splines cúbicos naturales a partir de los pares de datos (Year, Median AQI) para cada región.

Este método calcula los coeficientes de polinomios cúbicos por intervalos, generando una función continua y suave que representa la evolución del índice de calidad del aire a lo largo del tiempo.

También se creó la función `evaluarSpline`, la cual permite calcular el valor del spline en cualquier punto dentro del rango de años del dataset. Lo que permite tener una representación del comportamiento de la calidad del aire sin interrupciones entre los años, ya que se pueden estimar valores intermedios entre los datos originales.

## ETAPAS DE DESARROLLO

### Etapa 1: Preparación de datos (Completada)

En esta etapa se realizó la normalización del dataset y se agruparon los registros por medio de la asignación de una región geográfica con la función `asignar_region`. Posteriormente con la función `limpiar_agrupar()` se eliminaron los valores nulos en las variables seleccionadas.

Luego se van a agrupar los datos por región y año, se va a calcular el promedio de las variables Median AQI, el número de días según la clasificación del nivel de AQI y de los contaminantes principales.

### Etapa 2: Aplicación de Splines Cúbicos (Parcialmente completada)

Se implementó el método `splineNatural` para obtener los coeficientes de los splines que se usarán para la representación grafica y análisis de los registros anuales. Se utilizará con frontera natural, asumiendo segundas derivadas iguales a cero en los extremos del intervalo, debido a que no se cuenta con información adicional sobre la tasa de cambio del AQI en los años límite del dataset, por lo que la frontera natural resulta la más adecuada para este proyecto [2].

Con estos coeficientes se generarán funciones por tramos para cada intervalo de años, las cuales serán utilizadas para construir la representación gráfica del comportamiento del AQI.

Al momento se encuentra pendiente la implementación de una función que tome los splines resultantes y los grafique

### Etapa 3: Aplicación de Mínimos Cuadrados (Pendiente)

Se implementará un metodo para aplicar mínimos cuadrados sobre los datos del dataset, con el fin de poder identificar las posibles tendencias a futuro y realizar extrapolación de datos.

### Etapa 4: Validación del modelo (Pendiente)

Se realizará la comparación entre la curva generada por los splines cúbicos y las variables relacionadas con la distribución de los días según el nivel del AQI y con los días según su contaminante principal.

Esto con el proposito de verificar si el modelo representa adecuadamente el comportamiento real de los datos, así como identificar ciertos patrones que siga la variación de la calidad del aire.

### Etapa 5: Interpretación de los resultados (Pendiente)

Tras obtener los resultados de ambos métodos se realizará una comparación entre regiones de los modelos obtenidos. Se espera que las comparaciones permitan evidenciar:

- Tendencias crecientes o decrecientes
- Periodos con mayores variaciones
- Diferencias en la calidad del aire entre distintas regiones
- Implicaciones posibles sobre la salud pública

## PRINCIPALES RETOS PRESENTADOS

- Limpieza y estructuración del dataset: El dataset contiene miles de registros, por lo que fue necesario filtrar y organizar la información para evitar valores nulos y registros que no correspondan a algún estado perteneciente a una región definida por el Censo de Estados Unidos. Además, se realizó la agrupación de los datos con el objetivo de reducir la complejidad del análisis y trabajar con grupos representativos.
- Normalización de las variables: Fue necesario transformar variables relacionadas con los tipos de días y contaminantes en proporciones, con el fin de evitar que los valores absolutos distorsionen el análisis comparativo entre regiones. Esto se debe a que no todas las regiones presentan la misma cantidad de registros o días evaluados por año, por lo que la normalización permite una comparación consistente entre regiones.



# REFERENCIAS

- [1] U. S. E. P. Agency, “Technical assistance document for the reporting of daily air quality - the air quality index (AQI),” U.S. EPA, 2023. Available: <https://document.airnow.gov/technical-assistance-document-for-the-reporting-of-daily-air-quailty.pdf>
- [2] R. L. Burden and J. D. Faires, *Numerical analysis*, 10th ed. Cengage Learning, 2015.
- [3] J. Wadkins, “1980–2021 yearly air quality index from the EPA.” Kaggle, 2021. Available: <https://www.kaggle.com/datasets/threnjen/40-years-of-air-quality-index-from-the-epa-yearly>